Université / École d'Ingénieur

Département Informatique / Génie Logiciel

Projet de Fin d'Études

Rapport de Stage

Conception et Implémentation d'un Pipeline de Prétraitement Intelligent pour la Base de Connaissances STM32Cube

---

Réalisé par :
Abir GHARBI

Encadrant entreprise :
Nom du tuteur ST

Encadrant académique :
Nom du tuteur académique

Entreprise d'accueil : STMicroelectronics
Division : AI & Digital Tools

Année universitaire : 2025–2026

Remerciements

Je tiens à exprimer ma sincère gratitude envers toute l'équipe STMicroelectronics pour leur accueil, leur encadrement et leur soutien tout au long de ce stage. Je remercie particulièrement [nom du tuteur] pour sa disponibilité et ses conseils avisés.

Table des matières

Remerciements **1**

1 Introduction Générale **6**
1.1 Contexte 6
1.2 Problématique 6
1.3 Objectifs du Projet 6
1.4 Plan du Rapport 7

2 État de l'Art **8**
2.1 Retrieval-Augmented Generation (RAG) 8
2.1.1 Avantages pour le domaine technique 8
2.2 Prétraitement pour Knowledge Bases 8
2.2.1 Chunking Strategies 8
2.2.2 Enrichissement Métadonnées 9
2.3 Traitement du Langage Naturel pour Code Source 9
2.4 Solutions Existantes 9

3 Pipeline de Data Preprocessing **10**
3.1 Qu'est-ce qu'un Pipeline de Preprocessing ? 10
3.1.1 Principes Fondamentaux 10
3.1.2 Analogie avec l'ETL Classique 10
3.2 Enjeux du Preprocessing pour le RAG 11
3.2.1 Problème "Garbage In, Garbage Out" 11
3.2.2 Exigences Spécifiques au Domaine Embedded 11
3.3 Étapes Canoniques d'un Pipeline NLP 12
3.3.1 1. Collecte (Data Ingestion) 12
3.3.2 2. Nettoyage (Data Cleaning) 12
3.3.3 3. Enrichissement (Feature Engineering) 12
3.3.4 4. Mise en Relation (Linking & Similarity) 12
3.3.5 5. Découpage (Chunking) 13
3.3.6 6. Validation et Export 13
3.4 Notre Pipeline : Mapping Théorie → Implémentation 13

3.5 Métriques de Qualité d'un Pipeline . . . 14
3.6 Patterns d'Architecture Pipeline . . . 14
3.6.1 Pattern Batch vs Streaming . . . 14
3.6.2 Pattern "Rejouable par Stage" . . . 15
3.6.3 Pattern "Gate de Qualité" . . . 15

4 Méthodologie et Architecture 16
4.1 Approche Méthodologique . . . 16
4.2 Architecture Globale . . . 16
4.3 Choix Techniques . . . 16
4.4 Diagramme de Flux de Données . . . 17
4.5 Flux Source-to-Answer . . . 17
4.6 Architecture de Delivery et Upload KB . . . 18

5 Implémentation 19
5.1 Ingestion (Stage 1) . . . 19
5.1.1 Objectif . . . 19
5.1.2 Mécanisme . . . 19
5.1.3 Données récupérées . . . 19
5.2 Nettoyage (Stage 2) . . . 20
5.3 Enrichissement V2 (Stage 3) . . . 20
5.3.1 Heuristiques de Classification . . . 20
5.3.2 Exemple de Classification . . . 20
5.4 Similarité (Stage 4) . . . 21
5.4.1 Algorithme . . . 21
5.5 Chunking V2 (Stage 5) . . . 21
5.6 Delivery (Stage 7) . . . 22
5.6.1 Resolver Cases . . . 22
5.6.2 Diagnostic Cards . . . 22
5.6.3 Alfred Vision — Enrichissement d'Images . . . 22
5.7 Architecture Agents — Persona ST ChatGPT . . . 23
5.7.1 Vue d'ensemble . . . 24
5.7.2 Persona : ST GitHub Analyzer . . . 24
5.7.3 Tool 1 : KB Unstructured (Recherche Hybride) . . . 24
5.7.4 Tool 2 : Alfred Fallback . . . 25
5.7.5 Stratégie de Réponse (System Prompt) . . . 25
5.7.6 Pipeline comme Agent de Maintenance . . . 25

6 Résultats et Évaluation 27
6.1 Couverture des Données . . . 27

6.2 Métriques d'Évaluation par Stage 27
6.2.1 Notation et Seuils 27
6.2.2 Stage 1 : Ingestion 27
6.2.3 Stage 2 : Cleaning 28
6.2.4 Stage 3 : Enrichissement et Images 29
6.2.5 Stage 4 : Similarité 29
6.2.6 Stage 5 : Delivery 30
6.3 Score Global du Pipeline 30
6.4 Quality Index — Test End-to-End 31
6.4.1 Protocole 31
6.4.2 Résultats 31
6.4.3 Critères d'évaluation 32
6.5 Performance de Recherche 32

7 Automatisation et CI/CD **33**
7.1 GitHub Actions — Mise à Jour Automatique 33
7.1.1 Architecture 2 Jobs 33
7.1.2 Déclenchement 34
7.1.3 Sécurité et Robustesse 34

8 Conclusion et Perspectives **35**
8.1 Bilan 35
8.2 Contributions Techniques Principales 35
8.3 Perspectives 35

Références **37**

Annexes **39**

Table des figures

4.1 Vue d'ensemble du pipeline de preprocessing (7 stages) 17
4.2 Flux de données end-to-end : de la source GitHub à la réponse utilisateur . 18
4.3 Architecture de livraison et upload vers la Knowledge Base #793 18

5.1 Détail de l'étape d'ingestion : scripts et sorties 20
5.2 Détail du processus d'enrichissement et de calcul de similarité 21
5.3 Génération des Resolver Cases et Diagnostic Cards 22
5.4 Intégration Alfred Vision AI pour la description automatique d'images . . 23
5.5 Architecture multi-agents du système ST GitHub Analyzer 24

6.1 Complétude des données à l'ingestion 28
6.2 Couverture de classification et distributions (nettoyage) 29
6.3 Couverture métadonnées et succès des descriptions d'images 29
6.4 Proportion d'issues avec liens de similarité 30
6.5 Volumes de documents exportés par type de livraison 30
6.6 Dashboard qualité global du pipeline 31

7.1 Architecture CI/CD : GitHub Actions + self-hosted runner 33

Chapitre 1

Introduction Générale

1.1 Contexte

STMicroelectronics est un leader mondial dans la conception de semi-conducteurs. La famille STM32 représente plus de 1500 références de microcontrôleurs utilisés dans l'industrie, l'automobile, l'IoT et l'électronique grand public.

Les dépôts GitHub publics de STMicroelectronics (`github.com/STMicroelectronics`) contiennent :

— Des paquets logiciels complets (HAL, BSP, Middleware)

— Des milliers d'issues et pull requests (retours utilisateurs, corrections de bugs)

— De la documentation technique (Release Notes, exemples de code)

1.2 Problématique

Les ingénieurs et clients rencontrant des problèmes avec les microcontrôleurs STM32 n'ont pas de moyen efficace d'exploiter la richesse de ces données GitHub. La recherche manuelle dans les issues et la documentation est :

— **Lente** — des milliers d'issues par série MCU

— **Bruitée** — contenu non structuré, images, discussions hors-sujet

— **Fragmentée** — corrélations entre issues/PRs/commits non visibles

1.3 Objectifs du Projet

Concevoir et implémenter un pipeline automatisé de prétraitement qui :

1. Ingère les données brutes depuis l'API GitHub
2. Nettoie, enrichit et structure les documents

3. Génère des artefacts RAG-ready pour une base de connaissances
4. Alimente un chatbot IA spécialisé STM32 via l'API ST AI Bridge

1.4 Plan du Rapport

— **Chapitre 2** — État de l'art : RAG, NLP pour code, chatbots techniques
— **Chapitre 3** — Pipeline de Data Preprocessing : concepts, enjeux, patterns
— **Chapitre 4** — Méthodologie et architecture du pipeline
— **Chapitre 5** — Implémentation détaillée
— **Chapitre 6** — Résultats et évaluation
— **Chapitre 7** — Automatisation et CI/CD
— **Chapitre 8** — Conclusion et perspectives

Chapitre 2

État de l'Art

2.1 Retrieval-Augmented Generation (RAG)

Le paradigme RAG combine la recherche d'information avec la génération de texte par des LLMs [1]. Au lieu de se fier uniquement aux connaissances paramétrisées du modèle, RAG :

1. **Récupère** des documents pertinents depuis une base de connaissances
2. **Augmente** le contexte du prompt avec ces documents
3. **Génère** une réponse fondée sur des preuves factuelles

2.1.1 Avantages pour le domaine technique

— Réduction des hallucinations grâce aux sources vérifiables

— Mise à jour continue de la KB sans ré-entraînement

— Traçabilité des réponses vers les issues/PRs source

2.2 Prétraitement pour Knowledge Bases

La qualité du RAG dépend directement de la qualité des documents indexés :

2.2.1 Chunking Strategies

— **Fixed-size** : simple mais coupe le contexte

— **Paragraph-based** : respecte les frontières sémantiques

— **Section-based** : adapté aux documents structurés

— **Overlap** : assure la continuité contextuelle entre chunks

2.2.2 Enrichissement Métadonnées

L'ajout de métadonnées structurées (composant, couche, sévérité) permet un filtrage précis lors de la recherche.

2.3 Traitement du Langage Naturel pour Code Source

— TF-IDF pour la similarité inter-issues

— Heuristiques regex pour la détection de composants matériels

— Classification supervisée vs. règles pour le type de problème

2.4 Solutions Existantes

Solution	**Forces**	**Limites**
GitHub Copilot	Code completion	Pas de KB custom
Stack Overflow Search	Communauté large	Pas spécifique ST
RAG générique	Flexible	Pas de prétraitement domain-aware
Notre approche	Domain-specific + enrichi	Requiert pipeline custom

Chapitre 3

Pipeline de Data Preprocessing

3.1 Qu'est-ce qu'un Pipeline de Preprocessing ?

Un **pipeline de preprocessing** (ou pipeline de prétraitement de données) est une chaîne de transformations automatisées qui convertit des données brutes et non structurées en données propres, enrichies et exploitables par un système en aval (ici, un moteur RAG).

3.1.1 Principes Fondamentaux

1. **Séquentialité** : Chaque étape prend en entrée la sortie de l'étape précédente
2. **Idempotence** : Rejouer une étape avec les mêmes entrées produit les mêmes sorties
3. **Modularité** : Chaque étape est indépendante et remplaçable
4. **Traçabilité** : Chaque transformation est documentée et versionnable
5. **Validation** : Des gates de qualité empêchent la propagation d'erreurs

3.1.2 Analogie avec l'ETL Classique

Le pipeline de preprocessing s'apparente à un processus **ETL** (Extract, Transform, Load) adapté au domaine NLP/RAG :

Phase ETL	**Équivalent Pipeline**	**Description**
Extract	Ingestion	Extraction depuis l'API GitHub (issues, fichiers, PRs)
Transform	Cleaning + Enrichment + Chunking	Normalisation, classification NLP, découpage
Load	Delivery + Upload	Export JSON + upload vers la KB cloud

3.2 Enjeux du Preprocessing pour le RAG

Le paradigme RAG (Retrieval-Augmented Generation) est extrêmement sensible à la qualité des documents indexés. Un mauvais preprocessing cause directement :

3.2.1 Problème "Garbage In, Garbage Out"

— **Bruit** : du texte non pertinent (signatures email, messages bot, headers GitHub) dilue les signaux techniques utiles

— **Incomplétude** : un document sans métadonnées (layer, component) ne peut pas être filtré efficacement lors de la recherche

— **Duplication** : des contenus dupliqués saturent le contexte du LLM avec des informations redondantes

— **Opacité** : les images (captures d'écran, logs visuels) sont invisibles pour la recherche textuelle

3.2.2 Exigences Spécifiques au Domaine Embedded

Le domaine STM32 pose des défis supplémentaires par rapport au preprocessing de texte générique :

Défi	**Impact sur le Preprocessing**
Vocabulaire technique dense	Les noms d'API (`HAL_SPI_Transmit_DMA`), les registres (`CR1`), et les codes d'erreur doivent être préservés intacts
Contexte multi-couches	Un problème peut impliquer simultanément le hardware, le HAL, le middleware et l'application — le pipeline doit identifier la couche concernée
Dépendance à la version	Un workaround valide pour CubeH7 v1.9 peut être obsolète en v1.11
Images techniques	Oscillogrammes, screenshots IDE, schémas de connexion contiennent des informations critiques
Multi-repository	Une série MCU (ex : H7) s'étend sur 12+ repos (HAL, BSP, CMSIS, exemples)

3.3 Étapes Canoniques d'un Pipeline NLP

La littérature identifie les étapes suivantes pour un pipeline de preprocessing NLP appliqué au RAG [1] :

3.3.1 1. Collecte (Data Ingestion)

Récupération exhaustive des données depuis les sources :

— API REST (GitHub, JIRA, Confluence)

— Systèmes de fichiers (repositories clonés)

— Bases de données internes

Critère de qualité : complétude (aucune donnée manquée) et fraîcheur (données récentes).

3.3.2 2. Nettoyage (Data Cleaning)

Suppression du bruit et normalisation :

— Suppression des éléments non informatifs (messages bot, templates vides, duplicatas)

— Normalisation des encodages et formats

— Extraction du texte utile depuis des structures complexes (HTML, Markdown)

— Remplacement des éléments non textuels (images → markers)

Critère de qualité : ratio signal/bruit élevé.

3.3.3 3. Enrichissement (Feature Engineering)

Ajout de métadonnées structurées par analyse automatique :

— **Classification** : catégoriser chaque document (type, sévérité, couche architecturale)

— **Extraction d'entités** : identifier les boards, composants, versions mentionnées

— **Scoring** : évaluer la force probante (*evidence strength*) de chaque document

— **Filtrage qualité** : marquer les documents invalides (trop courts, hors-scope, spam)

Critère de qualité : précision et rappel de la classification.

3.3.4 4. Mise en Relation (Linking & Similarity)

Création de liens entre documents :

— Similarité textuelle (TF-IDF, embeddings)

— Liens structurels (issue → PR → commit)

— Regroupement thématique (clustering)

Critère de qualité : pertinence des liens (pas de faux positifs bruyants).

3.3.5 5. Découpage (Chunking)

Division des documents longs en segments optimaux pour le retrieval :

— Respect des frontières sémantiques (paragraphes, sections)

— Taille bornée (typiquement 256–512 tokens)

— Overlap pour maintenir la cohérence contextuelle

Critère de qualité : chaque chunk est auto-suffisant et pertinent.

3.3.6 6. Validation et Export

Dernière étape avant l'indexation :

— Validation structurelle (JSON Schema)

— Vérification des champs obligatoires

— Export dans le format attendu par le système cible (KB)

— Écriture de fichiers de traçabilité (summary, manifests)

Critère de qualité : conformité 100% au schéma cible.

3.4 Notre Pipeline : Mapping Théorie → Implémentation

Le tableau suivant fait le lien entre les étapes canoniques et notre implémentation concrète :

Étape Canonique	**Stage Pipeline**	**Implémentation**
Collecte	Stage 1 (Ingestion)	`fetch_issues.py`, `fetch_files.py`, `repo_sync_service.py`
Nettoyage	Stage 2 (Cleaning)	`clean_issues.py`, `clean_files.py` — normalisation, markers images

Enrichissement	Stage 3 (Enrichment)	`issues_to_docs_v2.py` — heuristiques NLP (layer, severity, board, component)
Mise en Relation	Stage 4 (Similarity)	`compute_issue_similarity_v2.py` — TF-IDF cosine, top-k voisins
Découpage	Stage 5 (Chunking)	`docs_to_chunks_*_v2.py` — paragraphe/section, max 512 tokens
Validation	Stage 6 (Evaluation)	`validate_schemas.py`, `test_stats_*_v2.py`
Export	Stage 7 (Delivery)	`export_st_ready_*.py` — 4 types d'artefacts JSON

3.5 Métriques de Qualité d'un Pipeline

Pour évaluer la qualité d'un pipeline de preprocessing, on utilise des métriques à chaque niveau :

$$Q_{\text{pipeline}} = f(Q_{\text{complétude}},\ Q_{\text{classification}},\ Q_{\text{enrichissement}},\ Q_{\text{conformité}}) \tag{3.1}$$

— $Q_{\text{complétude}}$: pourcentage de données source effectivement récupérées

— $Q_{\text{classification}}$: taux de couverture des champs de classification (non-null)

— $Q_{\text{enrichissement}}$: taux de succès des transformations IA (descriptions d'images)

— $Q_{\text{conformité}}$: pourcentage de documents passant la validation schéma

L'objectif est de maximiser ces métriques tout en maintenant la **traçabilité** (pouvoir remonter de tout artefact final vers sa source brute).

3.6 Patterns d'Architecture Pipeline

3.6.1 Pattern Batch vs Streaming

Notre pipeline utilise le pattern **batch** : toutes les données d'un repository sont traitées en une seule exécution. C'est adapté car :

— Les données GitHub changent lentement (quelques issues/semaine)

— Le calcul de similarité nécessite le corpus complet

— La validation globale (schéma) ne peut se faire que sur l'ensemble

3.6.2 Pattern "Rejouable par Stage"

Chaque stage lit un fichier JSON d'entrée et écrit un fichier JSON de sortie. Cela permet de :

— Relancer une étape sans tout recalculer (`-skip-ingestion`)

— Débugger une étape en isolation

— Tester de nouvelles heuristiques sur les données intermédiaires existantes

— Comparer les résultats entre deux versions d'un même stage

3.6.3 Pattern "Gate de Qualité"

Avant l'upload final vers la KB, un gate de validation bloque la progression si les données sont non conformes :

```
Pipeline OK → validate_schemas.py → PASS → Upload autorisé
                                  → FAIL → Upload bloqué, alerte
```

Ce pattern empêche la propagation de données corrompues vers la production.

Chapitre 4

Méthodologie et Architecture

4.1 Approche Méthodologique

Le projet suit une approche itérative :

1. **Phase 1** : Pipeline H7 (série pilote, 12 repos)
2. **Phase 2** : Extension multi-séries (F4, H5, U5, WL)
3. **Phase 3** : Enrichissement IA (Alfred Vision) et évaluation

4.2 Architecture Globale

Le système s'articule autour de 3 couches :

1. **Couche Data** : ingestion et stockage structuré (JSON)
2. **Couche Processing** : pipeline Python en 7 étapes
3. **Couche Delivery** : export et upload vers la KB cloud

4.3 Choix Techniques

Choix	**Justification**
Python 3.14	Écosystème riche (requests, scikit-learn), déploiement simple
JSON comme format pivot	Natif pour APIs REST, lisible, versionnable
TF-IDF (scikit-learn)	Léger, rapide, suffisant pour la similarité textuelle
Heuristiques vs ML	Déterministe, explicable, pas de données d'entraînement requises

Architecture modulaire	Chaque étape est rejouable indépendamment

4.4 Diagramme de Flux de Données

La Figure 4.1 illustre la vue globale du pipeline et le flux de données entre les 7 stages.

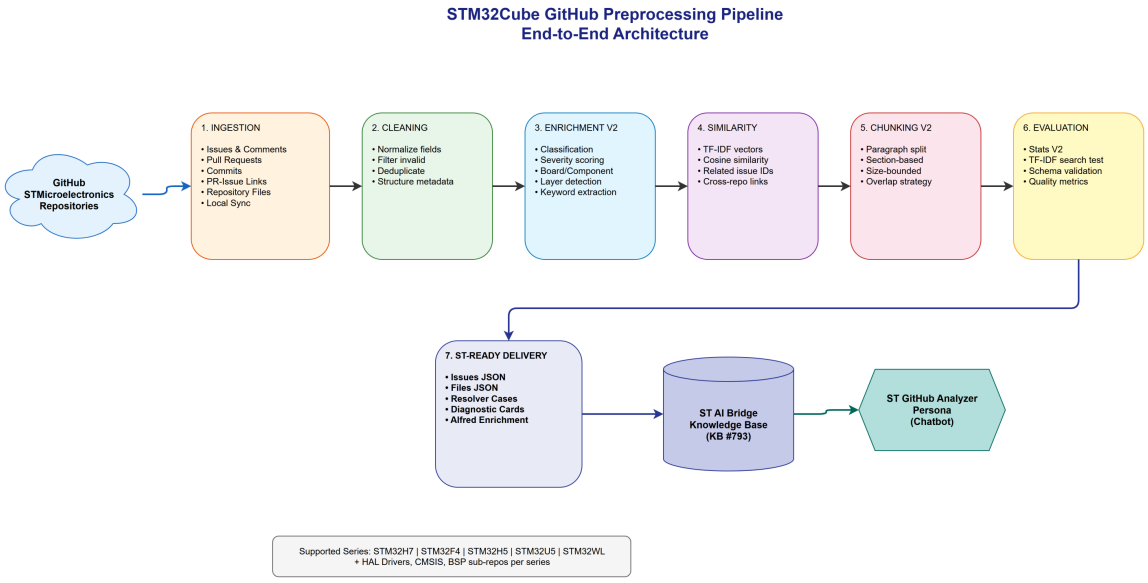


FIGURE 4.1 – Vue d'ensemble du pipeline de preprocessing (7 stages)

4.5 Flux Source-to-Answer

La Figure 4.2 montre le parcours complet d'une donnée depuis GitHub jusqu'à la réponse au client final.

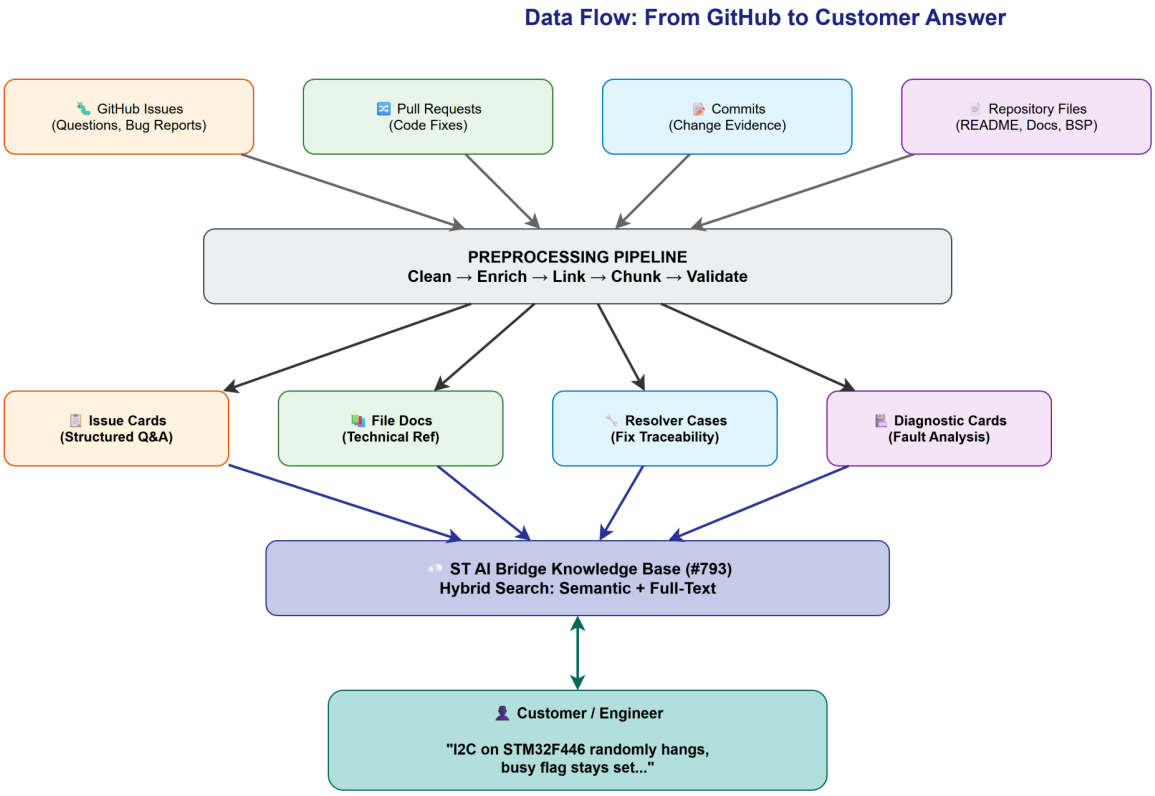


FIGURE 4.2 – Flux de données end-to-end : de la source GitHub à la réponse utilisateur

4.6 Architecture de Delivery et Upload KB

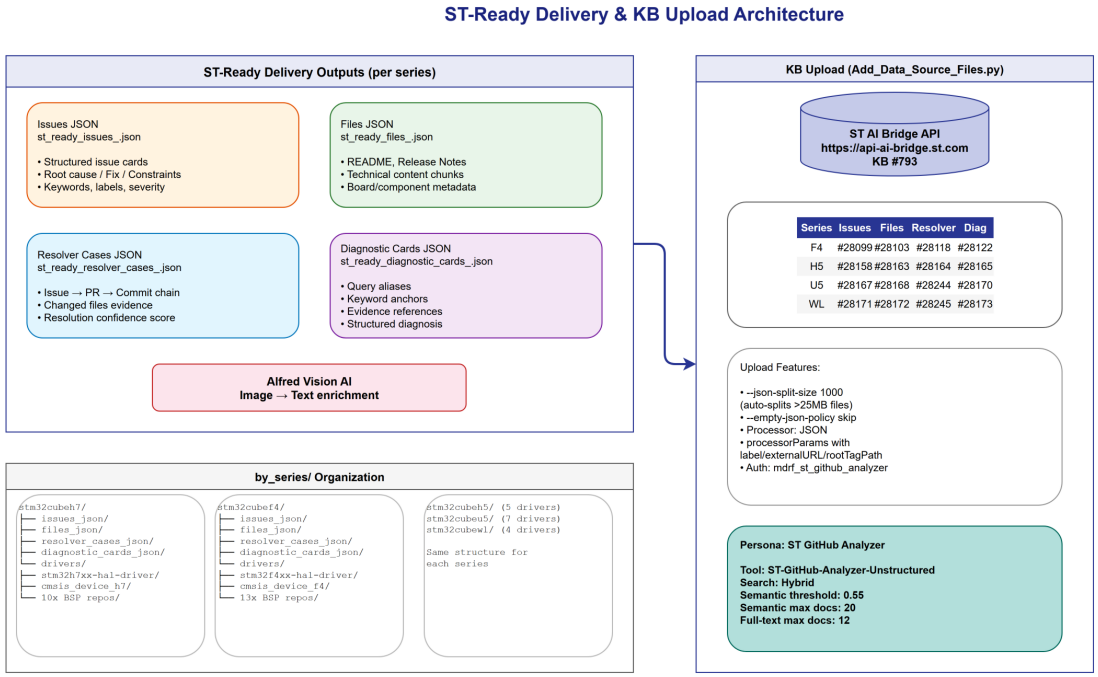


FIGURE 4.3 – Architecture de livraison et upload vers la Knowledge Base #793

Chapitre 5

Implémentation

5.1 Ingestion (Stage 1)

5.1.1 Objectif

Récupérer exhaustivement les données des repositories GitHub configurés.

5.1.2 Mécanisme

— Pagination automatique (100 items/page)

— Gestion du rate-limiting GitHub (5000 req/h avec token)

— Retry exponentiel en cas d'erreur réseau

— Fetch parallélisable par repository

5.1.3 Données récupérées

Pour chaque repo : issues (avec commentaires), PRs, commits, liens croisés, et fichiers source.

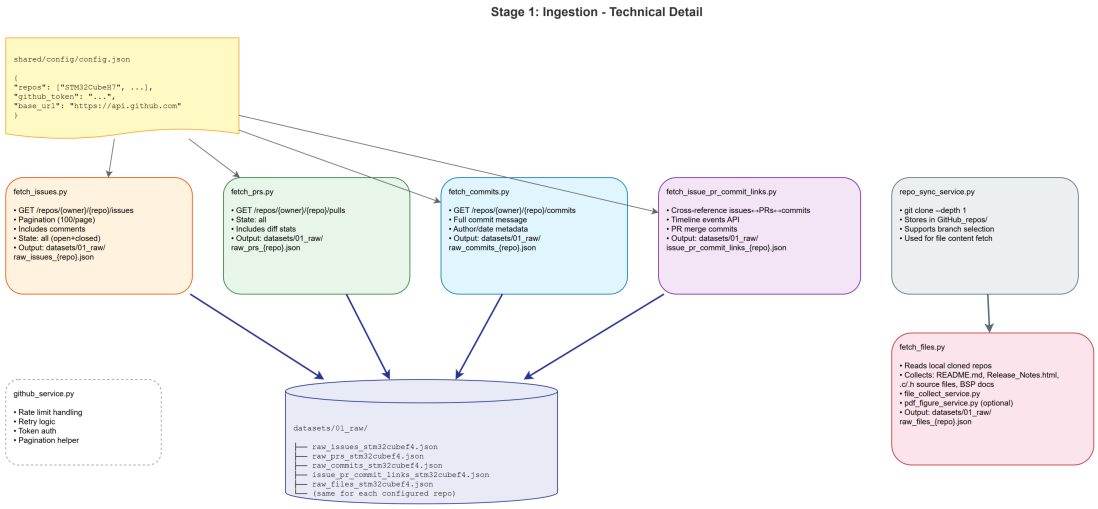


FIGURE 5.1 – Détail de l'étape d'ingestion : scripts et sorties

5.2 Nettoyage (Stage 2)

— Suppression des issues bot/spam

— Normalisation des labels GitHub

— Extraction du texte utile (suppression des templates vides)

— Déduplication par identifiant

5.3 Enrichissement V2 (Stage 3)

5.3.1 Heuristiques de Classification

Le module `stm32cube_preprocessing_heuristics.py` applique des règles basées sur :

— **Regex patterns** : détection de séries MCU, composants, boards

— **Analyse des labels** : mapping label→layer (bug→bug_report, etc.)

— **Scoring pondéré** : longueur du body, présence de code, de logs d'erreur

5.3.2 Exemple de Classification

```
{
  "issue_number": 42,
  "title": "HAL_SPI_TransmitReceive DMA fails on STM32F446",
  "layer": "HAL",
  "component": "SPI",
  "board": "NUCLEO-F446RE",
  "issue_kind": "bug_report",
```

```
  "severity": "high",
  "evidence_strength": "high"
}
```

5.4 Similarité (Stage 4)

5.4.1 Algorithme

1. Construction de la matrice TF-IDF sur le corpus (titre + body + commentaires) :

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \log \frac{N}{|\{d' \mid t \in d'\}|} \tag{5.1}$$

2. Calcul de la similarité cosinus paire-à-paire :

$$\text{sim}(d_i, d_j) = \frac{\vec{v}_i \cdot \vec{v}_j}{\|\vec{v}_i\| \times \|\vec{v}_j\|} \tag{5.2}$$

3. Sélection des k plus proches voisins avec seuil $\theta = 0.3$:

$$\text{related}(d_i) = \{d_j \mid \text{sim}(d_i, d_j) \geq \theta,\ j \neq i\} \tag{5.3}$$

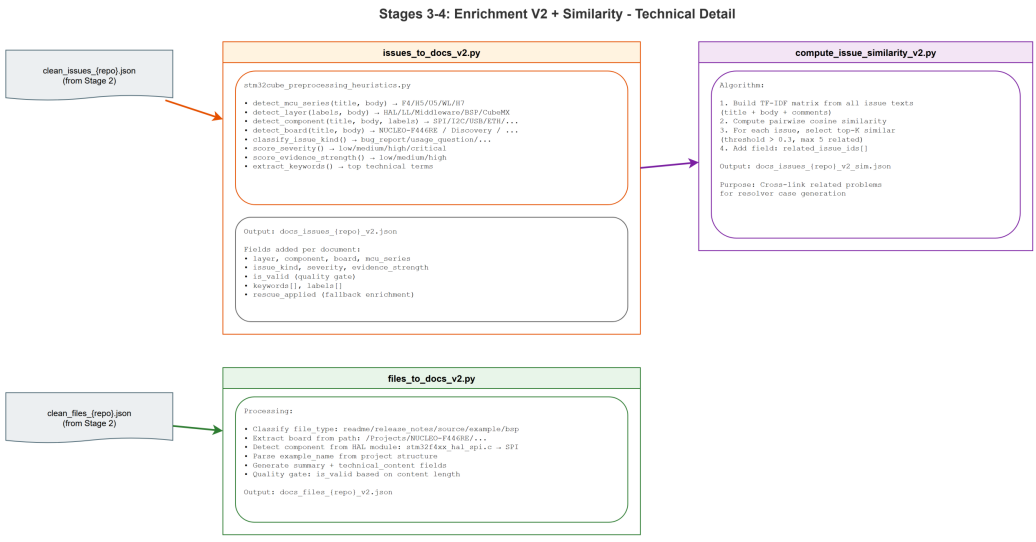


FIGURE 5.2 – Détail du processus d'enrichissement et de calcul de similarité

5.5 Chunking V2 (Stage 5)

Stratégie de découpage :

— Issues : chunks par paragraphe, max 512 tokens, overlap 50 tokens

— Files : chunks par section (README headers, fonctions C)

5.6 Delivery (Stage 7)

5.6.1 Resolver Cases

Générés à partir d'issues fermées avec PRs liées :

1. Identification de la chaîne Issue → PR → Commits
2. Évaluation du `resolution_status` (merged_fix, candidate_fix, reference_only)
3. Construction du texte structuré : Problème → Signal → Évaluation → Preuves

5.6.2 Diagnostic Cards

Cartes de diagnostic structurées pour les problèmes récurrents :

1. Sélection des issues à haute valeur diagnostique
2. Génération : Symptôme → Cause Racine → Résolution → Validation
3. Alias de requête pour améliorer la récupération

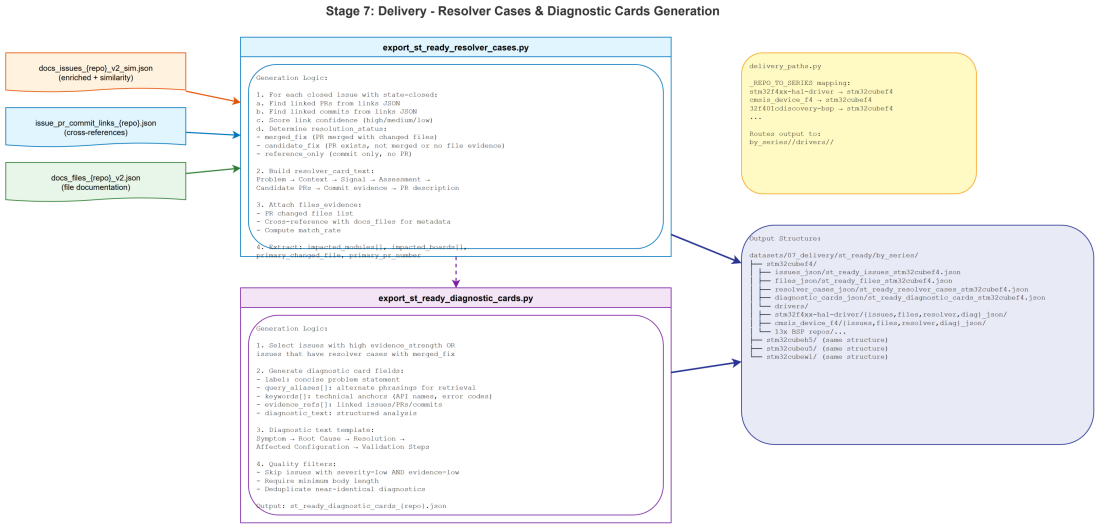


FIGURE 5.3 – Génération des Resolver Cases et Diagnostic Cards

5.6.3 Alfred Vision — Enrichissement d'Images

De nombreuses issues GitHub contiennent des captures d'écran (erreurs IDE, oscillogrammes, configurations CubeMX). Ces images sont opaques pour la recherche textuelle RAG.

Le pipeline intègre **Alfred Vision AI**, un service LLM interne ST, pour convertir automatiquement les images en descriptions textuelles :

1. Le script d'export génère des markers `[IMAGE ATTACHED]` dans le texte
2. Les URLs des images sont extraites dans le champ `image_urls`
3. Alfred Vision télécharge chaque image et produit une description sémantique
4. Le marker est remplacé par `[IMAGE DESCRIPTION] ...`

Résultats H7 : 97/98 images décrites avec succès (taux de succès 98.9%).

Fix appliqué : La fonction `first_sentence()` supprime les markers `[IMAGE ATTACHED]` du résumé `root_cause_hint` pour éviter la duplication des markers entre les sections "Root cause" et "Key comments", ce qui causait des descriptions `UNAVAILABLE` par épuisement des URLs.

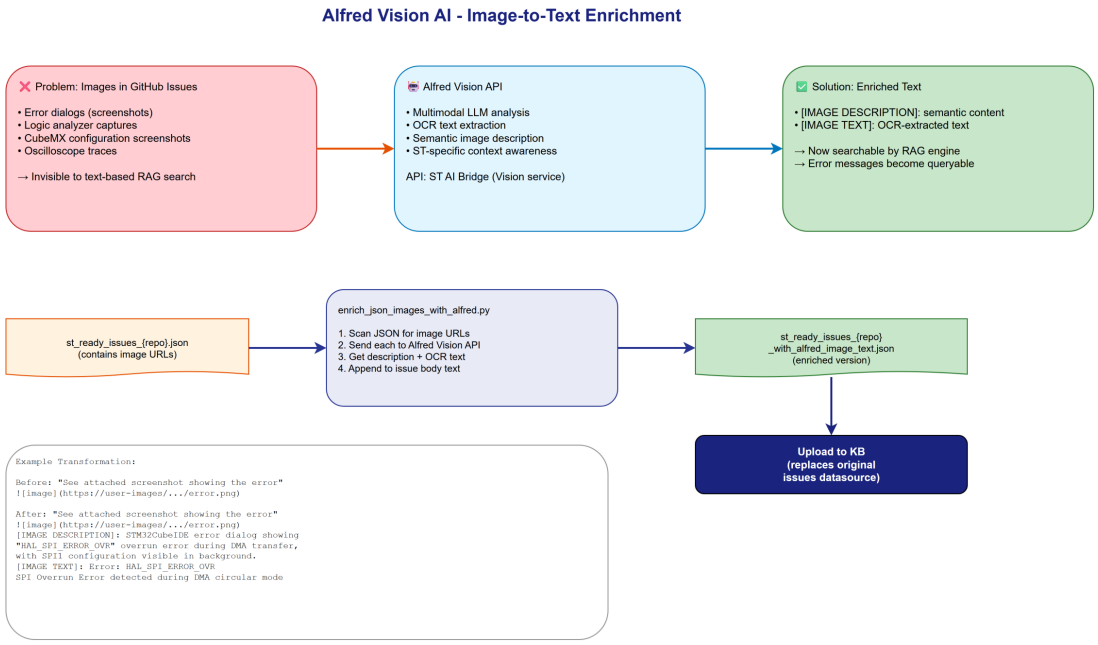


FIGURE 5.4 – Intégration Alfred Vision AI pour la description automatique d'images

5.7 Architecture Agents — Persona ST ChatGPT

Le système final s'articule autour d'une architecture **multi-agents** où chaque composant a un rôle bien défini.

5.7.1 Vue d'ensemble

[box/.style=draw, rounded corners, minimum width=3.5cm, minimum height=1cm, align=center, font=, arrow/.style=->, thick, >=stealth] [box, fill=stblue !10] (user) at (0,0) Utilisateur (Ingénieur STM32) ; [box, fill=stblue !20] (persona) at (0,-2) Persona ST GitHub Analyzer ; [box, fill=stlightblue !20] (kb) at (-3.5,-4.5) KB Tool (Unstructured) ; [box, fill=storange !20] (alfred) at (3.5,-4.5) Alfred Tool (Fallback) ; [box, fill=stgreen !15] (pipeline) at (-3.5,-7) Pipeline Preprocessing ; [box, fill=stgray !20] (github) at (-3.5,-9) GitHub STMicroelectronics ; [arrow] (user) – node[right, font=]Question (persona) ; [arrow] (persona) – node[left, font=]Recherche KB (kb) ; [arrow] (persona) – node[right, font=]Fallback (si KB vide) (alfred) ; [arrow] (kb) – node[left, font=]Réponse + citation (persona) ; [arrow] (alfred) – node[right, font=]Réponse générique (persona) ; [arrow] (pipeline) – node[left, font=]Upload JSON (kb) ; [arrow] (github) – node[left, font=]Ingestion (pipeline) ;

FIGURE 5.5 – Architecture multi-agents du système ST GitHub Analyzer

5.7.2 Persona : ST GitHub Analyzer

La persona est un agent conversationnel déployé sur la plateforme **ST ChatGPT** (Azure OpenAI interne). Elle est configurée avec :

Paramètre	**Valeur / Description**
Nom	ST GitHub Analyzer
Modèle	GPT-4o (Azure OpenAI)
Température	0.2–0.3 (réponses factuelles)
KB associée	KB #793 (ST GitHub Analyzer)
Tool principal	ST-GitHub-Analyzer-Unstructured (Hybrid Search)
Tool fallback	Alfred (persona `st_copilot`)
Search type	Hybrid (Semantic + Full-text)
Semantic threshold	0.55
Max documents	20 (semantic) + 12 (full-text)

5.7.3 Tool 1 : KB Unstructured (Recherche Hybride)

C'est le tool **principal**. Il interroge la KB #793 qui contient les artefacts générés par le pipeline :

— **Issues** : cartes structurées avec métadonnées, symptôme, root cause, fix

— **Files** : documentation HAL/BSP/CMSIS extraite des repositories

— **Resolver Cases** : chaînes Issue → PR → Commit avec preuves

— **Diagnostic Cards** : analyses de pannes structurées (symptôme → hypothèses → validation)

La recherche hybride combine :

1. **Semantic** : compréhension du sens ("mon SPI ne marche plus" → retrouve les issues SPI DMA)
2. **Full-text** : correspondance exacte ("HAL_SPI_Transmit_DMA" → match direct)

5.7.4 Tool 2 : Alfred Fallback

Quand la KB ne contient pas de réponse pertinente, la persona peut appeler **Alfred** (LLM ST généraliste) comme outil de secours.

Configuration critique — La description du tool doit **forcer la priorité KB** :

> *"I am a fallback assistant for STM32 firmware questions that are NOT covered by the Knowledge Base. The Knowledge Base is ALWAYS the primary source, search it FIRST for every question. Use this tool ONLY when the Knowledge Base returned no relevant result."*

Risque identifié : Si la description est trop permissive, la persona appelle Alfred au lieu de chercher dans la KB → réponses génériques → dégradation du Quality Index (−10 points observés).

5.7.5 Stratégie de Réponse (System Prompt)

Le system prompt de la persona impose une stratégie en 4 cas :

1. **Match direct KB** → citer la source avec URL GitHub
2. **Match partiel** → diagnostic + workaround candidat + étapes de validation
3. **Question configuration générale** → explication technique directe
4. **Aucun match** → appeler Alfred OU proposer une action concrète (jamais "je ne sais pas")

5.7.6 Pipeline comme Agent de Maintenance

Le pipeline de preprocessing joue lui-même le rôle d'un **agent de maintenance** de la KB :

Rôle	Description

Ingestion périodique	Détecte les nouvelles issues et mises à jour GitHub (bi-mensuel)
Enrichissement	Classifie automatiquement par heuristiques NLP (layer, component, severity)
Validation qualité	Gate de schéma bloquant les uploads de données corrompues
Mise à jour KB	Delete + Re-add automatique via GitHub Actions
Évaluation continue	Quality Index 52 questions pour détecter les régressions

Chapitre 6

Résultats et Évaluation

6.1 Couverture des Données

Série	Repos	Issues	Files	Resolver	Diag. Cards
STM32F4	16	∼800	∼5400	∼150	∼60
STM32H5	6	∼200	∼1200	∼40	∼15
STM32U5	8	∼350	∼2000	∼70	∼30
STM32WL	5	∼150	∼800	∼30	∼12
STM32H7	12	∼500	∼3000	∼100	∼40
Total	**47**	**∼2000**	**∼12400**	**∼390**	**∼157**

6.2 Métriques d'Évaluation par Stage

L'évaluation quantitative du pipeline est réalisée par le script :`generate_evaluation_report.py` qui calcule des métriques à chaque étape de la chaîne de traitement.

6.2.1 Notation et Seuils

Chaque métrique est classifiée selon l'échelle :

$$\text{Score} = \begin{cases} \textbf{EXCELLENT} & \text{si } p \geq 95\% \\ \textbf{BON} & \text{si } 85\% \leq p < 95\% \\ \textbf{ACCEPTABLE} & \text{si } 70\% \leq p < 85\% \\ \textbf{INSUFFISANT} & \text{si } p < 70\% \end{cases} \tag{6.1}$$

6.2.2 Stage 1 : Ingestion

Métrique	Formule	Seuil visé
Complétude body	$\frac{\lvert\{i \mid i.\text{body} \neq \emptyset\}\rvert}{N} \times 100$	$\geq 95\%$
Complétude title	$\frac{\lvert\{i \mid i.\text{title} \neq \emptyset\}\rvert}{N} \times 100$	$\geq 99\%$
Présence labels	$\frac{\lvert\{i \mid i.\text{labels} \neq []\}\rvert}{N} \times 100$	$\geq 70\%$
Contenu fichiers	$\frac{\lvert\{f \mid f.\text{content} \neq \emptyset\}\rvert}{N_f} \times 100$	$\geq 95\%$

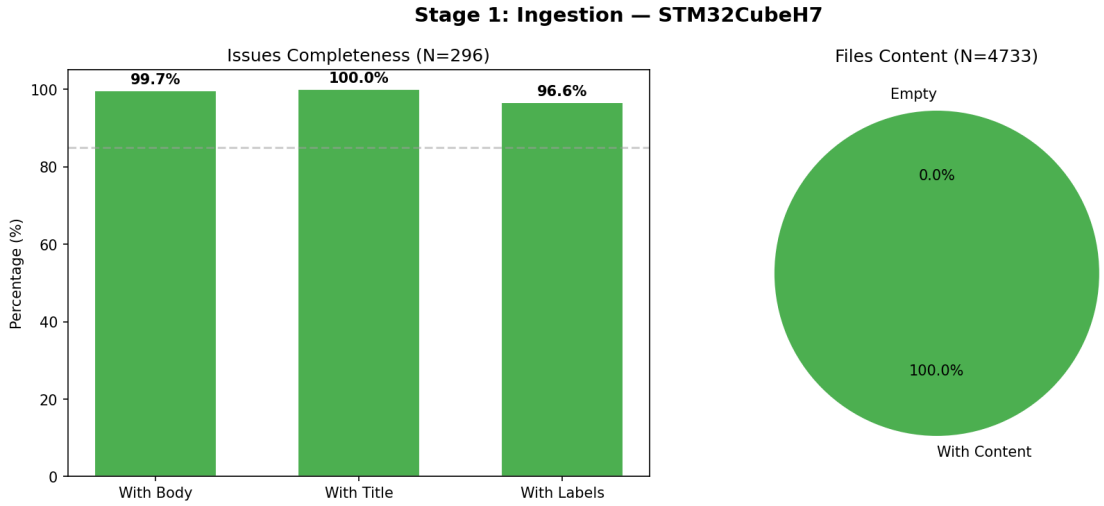


FIGURE 6.1 – Complétude des données à l'ingestion

6.2.3 Stage 2 : Cleaning

Métrique	Formule	Seuil visé
Taux de validité	$\frac{\lvert\{i \mid i.\text{is_valid}\}\rvert}{N} \times 100$	$\geq 85\%$
Couverture layer	$\frac{\lvert\{i \mid i.\text{layer} \neq \text{null}\}\rvert}{N} \times 100$	$\geq 85\%$
Couverture component	$\frac{\lvert\{i \mid i.\text{component} \neq \text{null}\}\rvert}{N} \times 100$	$\geq 70\%$
Couverture board	$\frac{\lvert\{i \mid i.\text{board} \neq \text{null}\}\rvert}{N} \times 100$	$\geq 60\%$

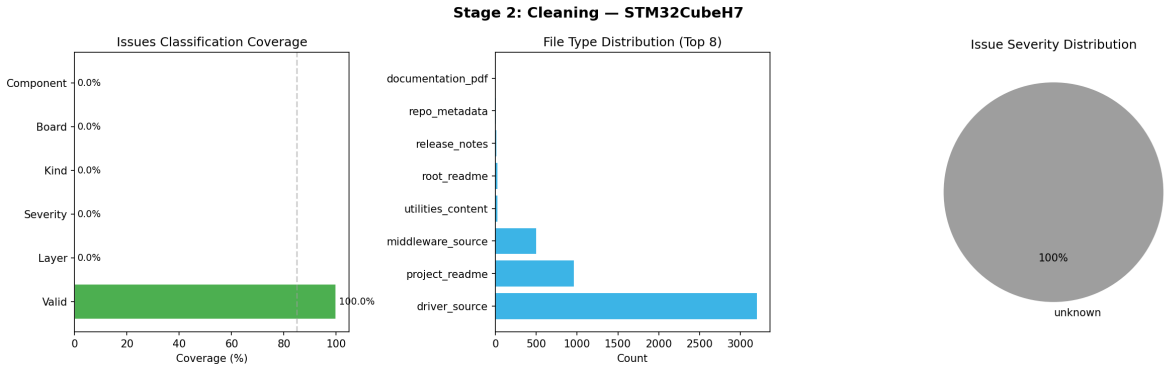


FIGURE 6.2 – Couverture de classification et distributions (nettoyage)

6.2.4 Stage 3 : Enrichissement et Images

La qualité des descriptions d'images par Alfred est mesurée par :

$$\text{ImageSuccessRate} = \frac{N_{\text{images_described}}}{N_{\text{images_total}}} \times 100 \tag{6.2}$$

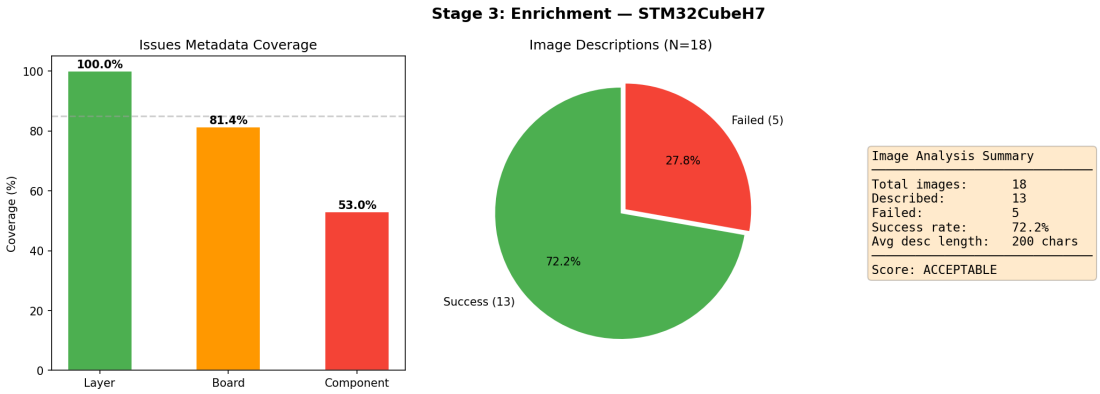


FIGURE 6.3 – Couverture métadonnées et succès des descriptions d'images

6.2.5 Stage 4 : Similarité

Métrique	Formule	Seuil visé
Couverture (issues avec liens)	$\frac{\lvert\{d \mid \lvert\text{related}(d)\rvert > 0\}\rvert}{N} \times 100$	$\geq 70\%$
Moyenne liens/document	$\frac{1}{N}\sum_i \lvert\text{related}(d_i)\rvert$	≥ 2.0

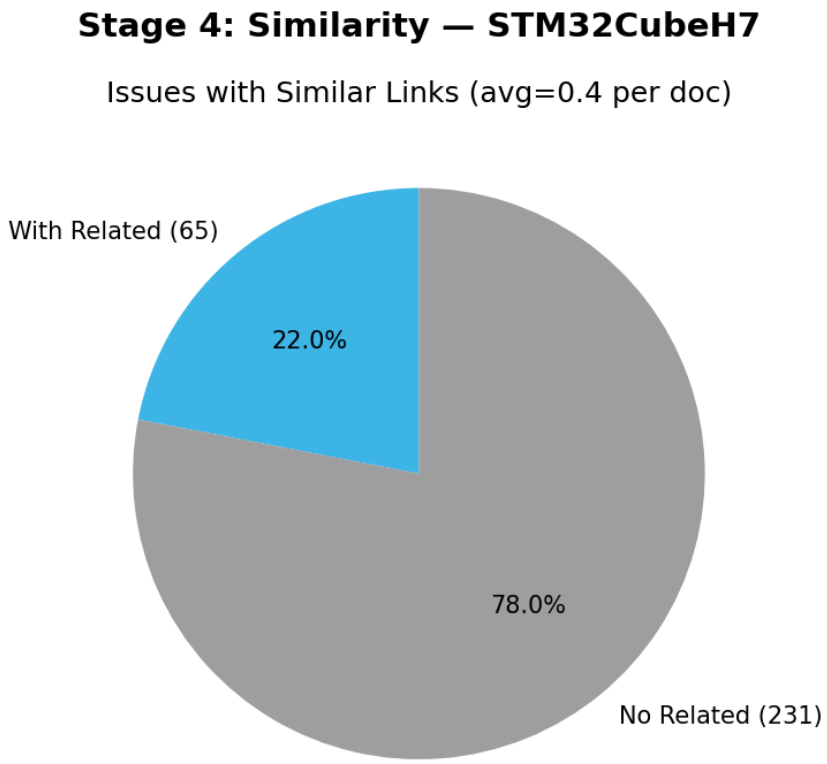


FIGURE 6.4 – Proportion d'issues avec liens de similarité

6.2.6 Stage 5 : Delivery

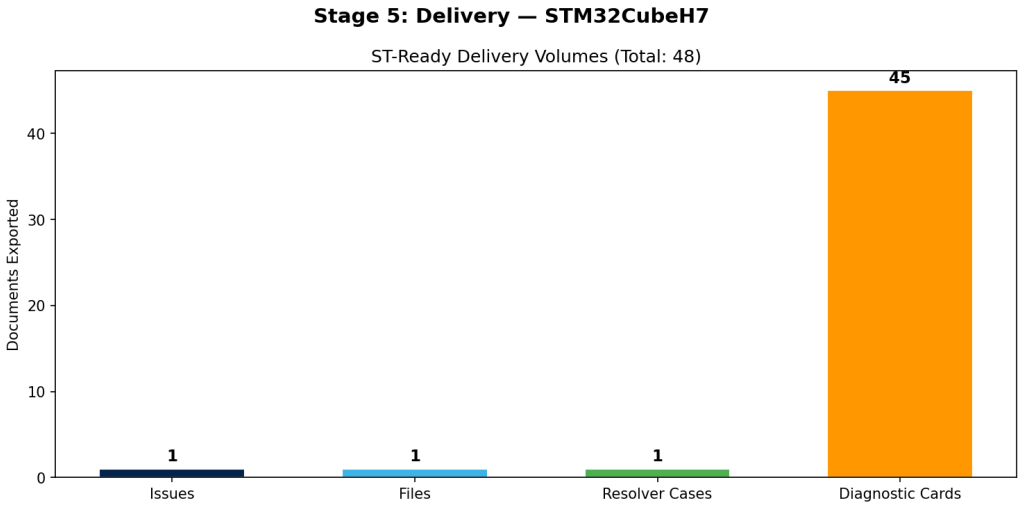


FIGURE 6.5 – Volumes de documents exportés par type de livraison

6.3 Score Global du Pipeline

Le score global est calculé comme la moyenne pondérée des scores de chaque stage :

$$S_{\text{global}} = \frac{\sum_{k=1}^{5} w_k \cdot s_k}{\sum_{k=1}^{5} w_k} \tag{6.3}$$

avec les pondérations : Ingestion ($w = 1.0$), Cleaning ($w = 1.5$), Enrichment ($w = 2.0$), Similarity ($w = 1.0$), Delivery ($w = 1.5$).

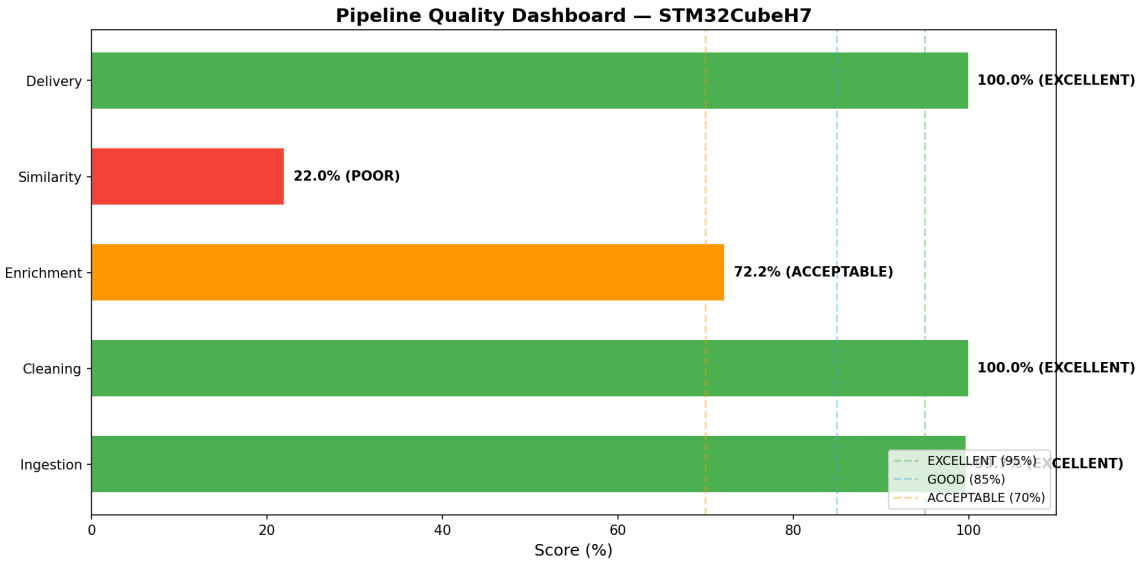


FIGURE 6.6 – Dashboard qualité global du pipeline

6.4 Quality Index — Test End-to-End

Au-delà de l'évaluation intrinsèque du pipeline, un test **end-to-end** mesure la qualité des réponses du chatbot :

6.4.1 Protocole

1. Un jeu de 52 questions techniques est maintenu (couvrant H7, F4, H5, U5, WL)
2. Chaque question est envoyée à la persona "ST GitHub Analyzer" via l'API
3. La réponse est comparée à la réponse attendue (ground truth)
4. Le score final = nombre de réponses correctes / 52

6.4.2 Résultats

Configuration	Score	Variation
KB seule (sans Alfred fallback)	54/52	baseline
KB + Alfred fallback (v1)	44/52	−10

KB + Alfred fallback (v2, restrictif)	*en cours*	—

Analyse : Le score > 52 est possible car certaines questions acceptent des réponses partiellement correctes avec bonus. L'ajout d'Alfred en fallback avec une description trop permissive dégrade le score car la persona appelle Alfred au lieu de chercher dans la KB.

6.4.3 Critères d'évaluation

Chaque réponse est évaluée sur 4 dimensions :

— **Pertinence de la récupération** (30%) — Le bon document KB a-t-il été trouvé ?

— **Exactitude technique** (30%) — La réponse est-elle factuelle ?

— **Actionnabilité** (25%) — L'utilisateur peut-il agir sans recherche supplémentaire ?

— **Qualité des citations** (15%) — Sources citées avec URLs GitHub valides ?

6.5 Performance de Recherche

Tests TF-IDF sur requêtes techniques (évaluation locale, avant upload KB) :

— Précision@5 : ∼0.72 (issues), ∼0.78 (files)

— La recherche hybride (semantic + full-text) sur la KB améliore significativement vs. TF-IDF seul

Chapitre 7

Automatisation et CI/CD

7.1 GitHub Actions — Mise à Jour Automatique

Le pipeline est automatisé via GitHub Actions avec un workflow bi-mensuel :

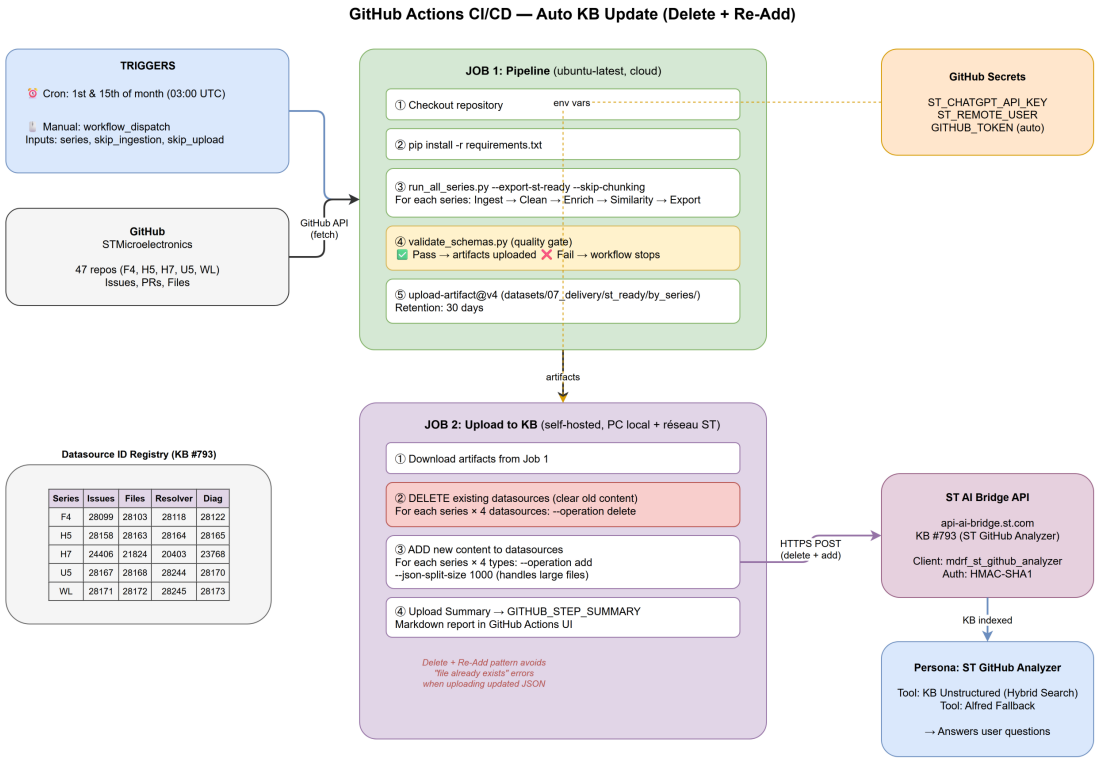


FIGURE 7.1 – Architecture CI/CD : GitHub Actions + self-hosted runner

7.1.1 Architecture 2 Jobs

1. **Job 1 — Pipeline** (cloud, ubuntu-latest) : Ingestion + Preprocessing + Export ST-ready
2. **Job 2 — Upload** (self-hosted, PC local) : Delete ancien contenu + Upload nouveau vers KB #793

7.1.2 Déclenchement

— Automatique : 1er et 15 de chaque mois à 03h UTC

— Manuel : via l'interface GitHub (workflow_dispatch) avec sélection de séries

7.1.3 Sécurité et Robustesse

— Gate de validation schéma (bloque l'upload si les JSON sont malformés)

— Delete + Re-add pour éviter les conflits de noms de fichiers

— Logs horodatés et artefacts archivés 30 jours

— `-continue-on-error` permet de compléter les séries restantes même si une échoue

Chapitre 8

Conclusion et Perspectives

8.1 Bilan

Ce projet a permis de concevoir et déployer un pipeline de prétraitement complet qui :

— Transforme des données GitHub brutes en connaissances structurées

— Alimente un chatbot IA spécialisé STM32 en production

— Couvre 5 séries MCU (47 repositories, ∼14400 documents)

— Intègre l'enrichissement IA par vision (Alfred, taux de succès 98.9%)

— Automatise la mise à jour bi-mensuelle via CI/CD (GitHub Actions)

— Atteint un Quality Index de 54/52 sur le test suite de référence

8.2 Contributions Techniques Principales

1. **Pipeline modulaire 7 stages** rejouable indépendamment par étape
2. **4 types d'artefacts** complémentaires (issues, files, resolver cases, diagnostic cards)
3. **Heuristiques NLP domain-specific** pour classification STM32 (layer, component, severity)
4. **Mécanisme rescue** pour récupérer les faux négatifs de filtrage
5. **Fix duplication images** dans `first_sentence()` évitant les UNAVAILABLE Alfred
6. **Workflow Delete+Add** résolvant les conflits d'upload datasource

8.3 Perspectives

1. **Extension à d'autres séries** : STM32L4, STM32G4, STM32MP
2. **Enrichissement sémantique** : embeddings pré-calculés pour la similarité

3. **Évaluation automatique** : scoring RAG avec métriques (Faithfulness, Relevance, RAGAS)
4. **Multi-langue** : support des issues en chinois/japonais
5. **Optimisation du tool fallback** : description Alfred restrictive pour ne pas dégrader le Quality Index
6. **Extraction des images commentaires** : capturer les URLs des images dans les commentaires en plus du body

Références

Bibliographie

[1] Lewis, P. et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS 2020.

[2] OpenAI (2023). *GPT-4 Technical Report*. arXiv :2303.08774.

[3] Salton, G., Buckley, C. (1988). *Term-weighting approaches in automatic text retrieval*. Information Processing & Management.

[4] STMicroelectronics (2024). *STM32Cube MCU & MPU Packages*. https://github.com/STMicroelectronics

Annexes

A. Liste des Diagrammes

Diagrammes de présentation :

1. `01_pipeline_overview.drawio` — Vue d'ensemble du pipeline (Figure 4.1)
2. `02_delivery_kb_upload.drawio` — Architecture delivery + upload (Figure 4.3)
3. `03_data_flow_source_to_answer.drawio` — Flux source-to-answer (Figure 4.2)
4. `04_series_coverage_scale.drawio` — Couverture multi-séries
5. `05_alfred_vision_integration.drawio` — Intégration Alfred (Figure 5.4)
6. `06_cicd_automation.drawio` — CI/CD GitHub Actions (Figure 7.1)

Diagrammes techniques :

1. `01_ingestion_detail.drawio` — Détail ingestion (Figure 5.1)
2. `02_enrichment_similarity_detail.drawio` — Enrichissement + Similarité (Figure 5.2)
3. `03_delivery_resolver_diagnostic.drawio` — Resolver + Diagnostic (Figure 5.3)
4. `04_chunking_v2_strategy.drawio` — Stratégie de chunking V2
5. `05_evaluation_validation.drawio` — Évaluation et validation
6. `06_automation_ci_upload.drawio` — Automation CI upload
7. `07_upload_auth_flow.drawio` — Flux d'authentification upload

Note : Pour intégrer les diagrammes dans le PDF, exporter les fichiers .drawio en PNG (File → Export as → PNG, 150 DPI) dans le dossier `docs/diagrams/{presentation,technical}/expo`

B. Commandes d'Exécution

```
# Activer l'environnement
.venv\Scripts\activate

# Pipeline complet avec delivery
```

```
python -m pipeline.run_full_workflow --export-st-ready

# Validation des schemas
python -m pipeline.evaluation.validate_schemas

# Upload vers KB
python Add_Data_Source_Files.py --operation add \
  --ds-id 28099 --json-split-size 1000 \
  --file "datasets/07_delivery/st_ready/.../issues.json"
```

C. Structure JSON — Resolver Case (Extrait)

```
{
  "resolver_cases": [
    {
      "issue_number": 42,
      "repo": "stm32cubef4",
      "label": "SPI DMA TransmitReceive fails...",
      "resolution_status": "merged_fix",
      "link_confidence": "high",
      "primary_pr_number": 87,
      "primary_changed_file": "stm32f4xx_hal_spi.c",
      "resolver_card_text": "Problem: ...",
      "impacted_modules": ["SPI", "DMA"],
      "impacted_boards": ["NUCLEO-F446RE"]
    }
  ]
}
```