PFE 2026 - Overview de projet

Assistant RAG pour STM32Cube :

De la préparation des données GitHub à la comparaison avec la solution RAG ST

ST Restricted

Contexte & Motivation

- STMicroelectronics publie de nombreux **dépôts GitHub STM32Cube.**
- Ces dépôts contiennent une **énorme quantité d'information** utile pour :
  - résoudre des problèmes,
  - comprendre des bugs connus,
  - trouver des exemples adaptés à une carte ou un périphérique.

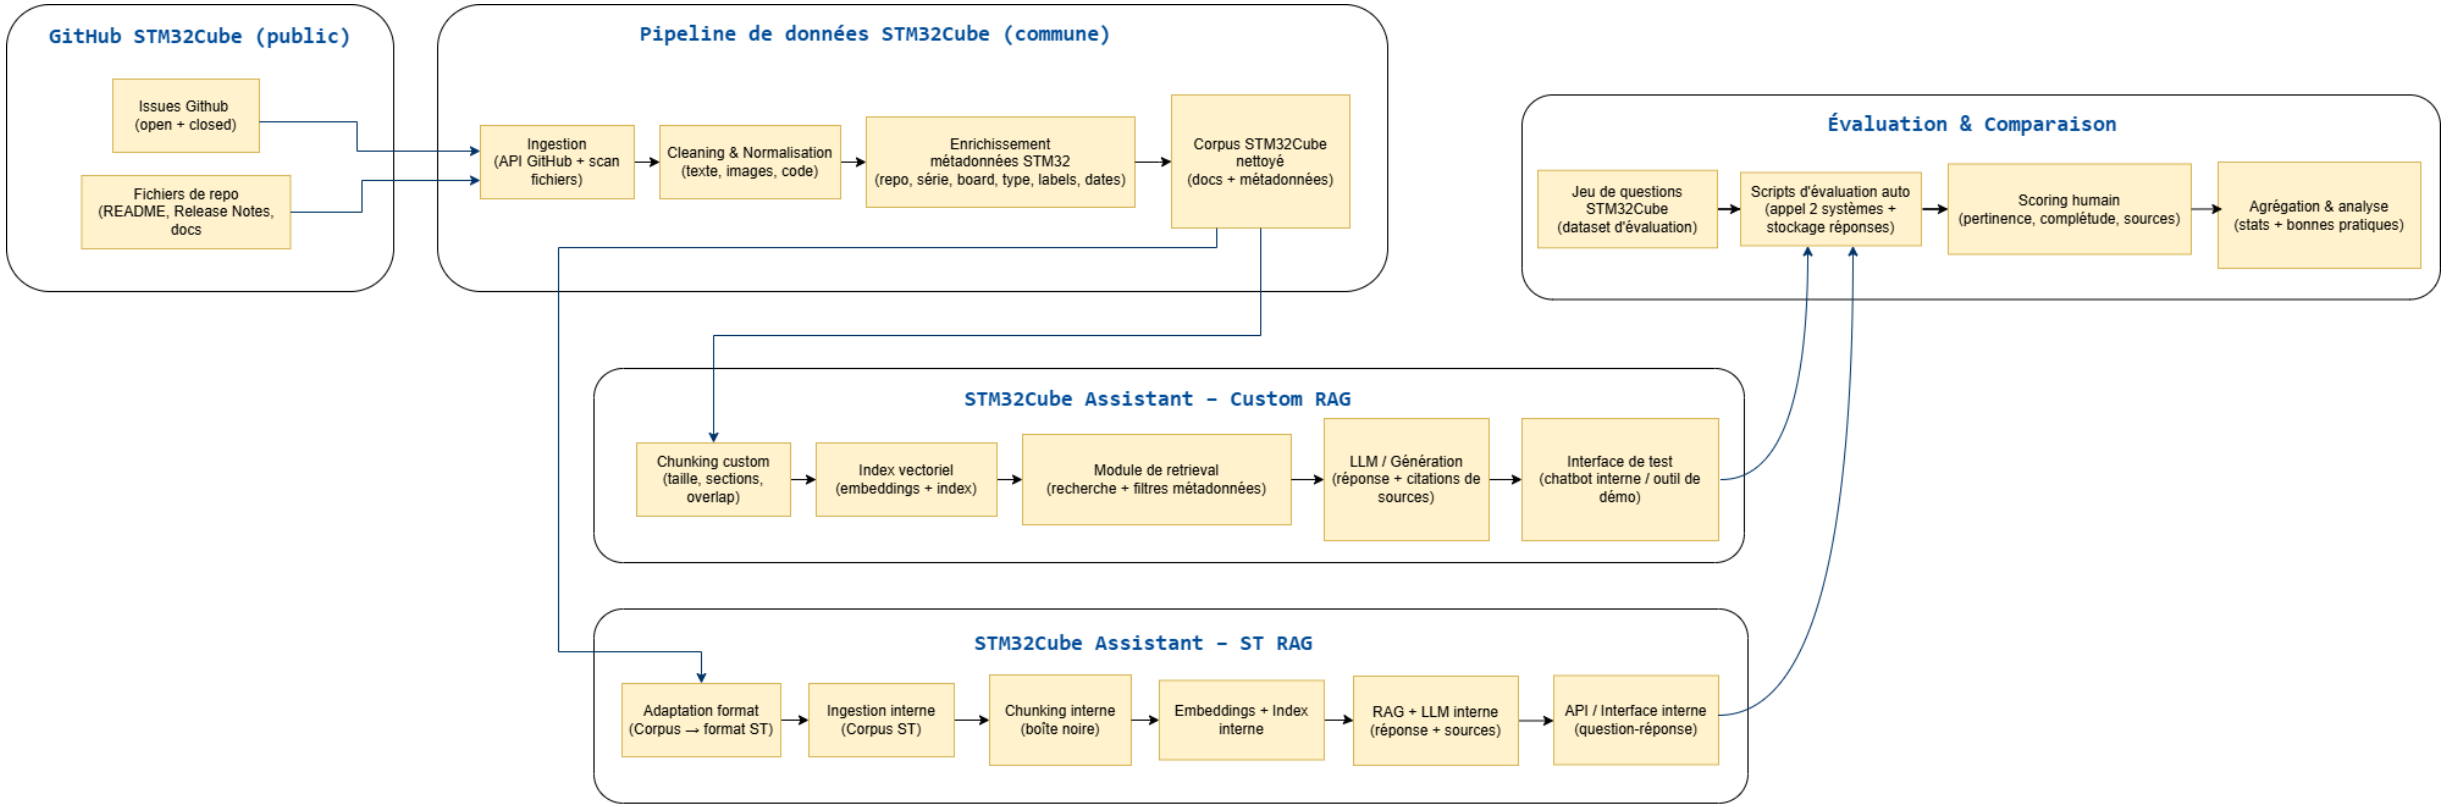
- Aujourd'hui, un utilisateur (interne ou externe) doit :
  - chercher manuellement dans les issues, README, release notes,
  - poser des questions récurrentes au support.

Objectif global :

→ Exploiter ces données GitHub STM32Cube pour construire un assistant RAG / chatbot capable d'aider au support technique, et comparer une solution RAG custom à la solution RAG professionnelle utilisée en interne par ST.

ST Restricted

Architecture globale



- **Scripts d'évaluation auto :**

→ Exécution batch du jeu de questions sur les 2 systèmes + stockage des réponses dans un fichier.

- **Scoring humain:**

→ Notation manuelle des réponses (pertinence, complétude, qualité des sources) par un évaluateur STM32.

- **Agrégation & analyse :**

→ Scripts de calcul de statistiques à partir des notes humaines, puis analyse des résultats pour en tirer des bonnes pratiques.

ST Restricted

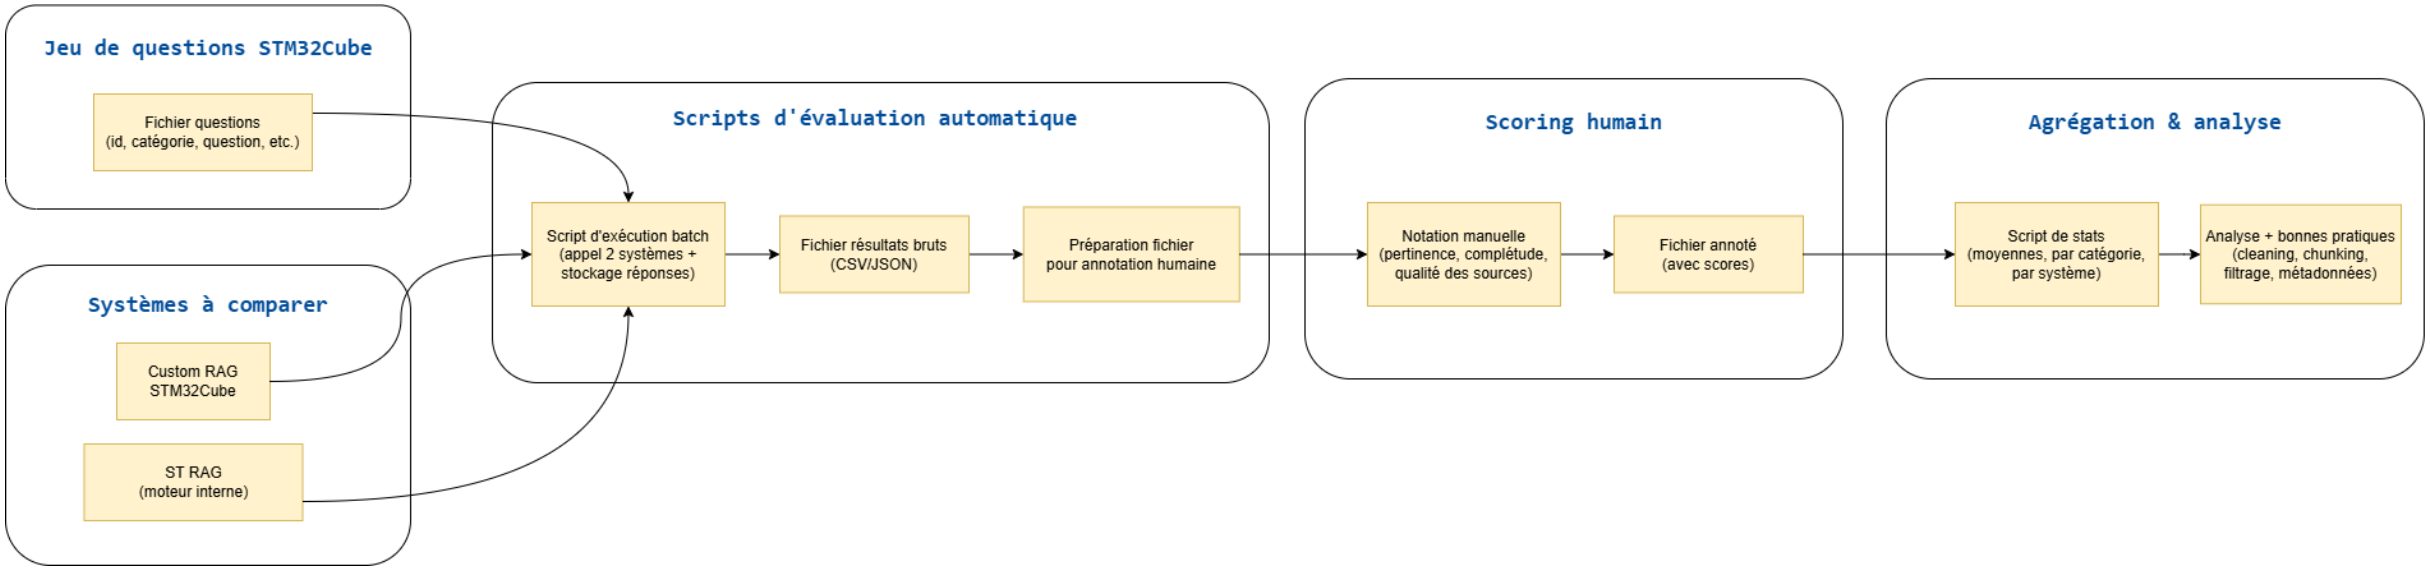
Évaluation comparative (automatisée)

Objectif :

Comparer, sur le **même corpus STM32Cube GitHub** et le **même jeu de questions**, deux systèmes :

- Custom RAG STM32Cube ,
- ST RAG (moteur RAG interne ST, alimenté par le corpus nettoyé),

afin de mesurer leur performance et d'en déduire des bonnes pratiques de préparation des données.



ST Restricted

Métriques d’évaluation

1. Métriques subjectives (scoring humain) :

Pour chaque (question, système) :

- **Pertinence (relevance)** – score 0,1,2
  - 0 : hors sujet ou majoritairement incorrect,
  - 1 : partiellement pertinent, mais incomplet / trop général,
  - 2 : bien pertinent, répond directement à la question.
- **Complétude (completeness)** – score 0,1,2
  - 0 : manque des éléments indispensables,
  - 1 : répond à la question principale mais oublie des détails importants,
  - 2 : couvre les points techniques essentiels attendus.
- **Qualité des sources (sources_quality)** – score 0,1,2
  - 0 : pas de sources, ou sources peu pertinentes,
  - 1 : au moins une source utile mais pas optimale (doc partielle, mauvais exemple),
  - 2 : sources bien choisies (bonne issue, bon README, bonne release note), cohérentes avec la réponse.



Ces trois métriques font ressortir :

- si le système comprend la question,
- s’il donne une réponse vraiment exploitable,
- s’il pointe vers les bons artefacts STM32Cube.

ST Restricted

Métriques d’évaluation

2. Métriques automatiques simples :

Calculées sans jugement humain, pour aider l’analyse :

- **Nombre de sources citées** par réponse.
- **Types de sources** utilisés :
  - proportion d’issues, README, release notes, docs.
- **Recouvrement avec les sources attendues** :
  - indicateur binaire si l’une des sources contient un mot clé attendu (nom d’exemple, board, etc.).
- **Longueur de la réponse**.



Ces métriques ne remplacent pas le scoring humain, mais complètent l’analyse.

ST Restricted

Apports et valeur du projet pour ST

1. Apports techniques :

- **Pipeline STM32Cube GitHub "prête pour le RAG" :**
  - Scripts pour récupérer automatiquement :
    - les issues GitHub,
    - les fichiers importants.
  - Nettoyage du contenu (Markdown, code, images, texte inutile).
  - Ajout de métadonnées STM32 (série, carte, type de doc, labels de bug…).
  - Production d'un **format commun** de documents utilisable :
    - par le **moteur RAG interne ST**,
    - par mon **RAG STM32Cube (Custom RAG)**.

ST Restricted

Apports et valeur du projet pour ST

- **Custom RAG STM32Cube :**
  - Implémentation d'un RAG complet sur le corpus GitHub :
    - plusieurs stratégies de chunking,
    - index vectoriel + recherche,
    - génération de réponses avec citations de sources,
    - petite interface de test (chatbot / démo).
  - Sert de **référence (baseline)** pour comparer avec le moteur RAG ST sur les mêmes données.
- **Intégration avec le moteur RAG interne ST :**
  - Adaptation des documents nettoyés au format attendu par la plateforme RAG interne.
  - Tests du moteur ST sur un cas réel : STM32Cube + GitHub.
  - Identification :
  - des points forts (types de questions où il est très bon),
  - des limites (types de questions ou de docs où il est moins bon).

ST Restricted

Apports et valeur du projet pour ST

2. Apports méthodologiques :

- **Cadre d'évaluation réutilisable :**
  - Définition d'un jeu de questions STM32Cube (dataset d'évaluation).
  - Scripts pour :
    - poser automatiquement ces questions aux 2 systèmes (Custom RAG + ST RAG),
    - stocker toutes les réponses dans un fichier.
  - Format d'annotation standard :
    - colonnes de scoring : pertinence, complétude, qualité des sources.
  - Scripts de statistiques pour calculer les résultats

- **Comparaison claire entre les deux RAG :**
  - Calcul de métriques pour chaque système :
    - moyenne de pertinence,
    - moyenne de complétude,
    - qualité des sources.
  - Comparaison :
    - **ST vs Custom**,
    - par type de question (doc, bug, configuration, release notes…).
  - Documentation d'exemples concrets :
    - cas où ST est meilleur,
    - cas où mon Custom RAG s'en sort bien,
    - cas où les deux sont en difficulté.

ST Restricted

Apports et valeur du projet pour ST

- **Bonnes pratiques documentées :**

  À partir des résultats, je propose des recommandations pour :

  - le **cleaning** des données GitHub STM32Cube,
  - le **chunking** des README, issues, release notes,
  - **l'usage des métadonnées** et des filtres (série, board, type de doc, etc.)

- Ces bonnes pratiques sont réutilisables pour :

  - un futur **assistant STM32Cube interne** pour FAE / support,
  - un futur **bot GitHub d'aide aux issues**
  - (ex. GitHub App qui suggère automatiquement, dans un commentaire, des issues similaires / README / release notes pertinentes),
  - d'autres projets RAG internes sur d'autres corpus.

ST Restricted

Apports et valeur du projet pour ST

3. Valeur stratégique pour ST :

- **Accélération :**

  - Mon Travail fournit déjà :
    - La **pipeline de données ,**
    - les **scripts d'évaluation** (pour tester la qualité des réponses),
    - un **retour d'expérience** sur l'utilisation du moteur RAG interne avec ce corpus.

  → Si ST veut aller plus loin (assistant interne, bot GitHub…), ils ne repartent pas de zéro.

- **Réduction du risque :**

  - Grâce à l'évaluation :
    - ST sait ce que le moteur RAG interne sait faire et ne sait pas faire sur STM32Cube GitHub.
    - Ils ont des indicateurs pour décider :
      - est-ce qu'on utilise l'assistant seulement pour proposer des liens / docs,
      - ou aussi pour rédiger des réponses plus complètes,
      - quels points il faut encore améliorer avant une exposition client.

    → Moins de risque d'un chatbot qui donne des réponses incorrectes en public.

→ ST dispose d'un **savoir-faire réutilisable** pour d'autres assistants RAG (pas seulement STM32Cube).

ST Restricted

Our technology starts with You



Find out more at www.st.com

© STMicroelectronics - All rights reserved.
ST logo is a trademark or a registered trademark of STMicroelectronics International NV or its affiliates in the EU and/or other countries.
For additional information about ST trademarks, please refer to www.st.com/trademarks.
All other product or service names are the property of their respective owners.